Ejercicio 8. Q-learning en Cliff Walking

Programé un agente para una cuadrícula de 4 filas y 12 columnas. Cada paso cuesta -1. Si cae al acantilado recibe -100 y vuelve al inicio, pero el episodio sigue. Entré a la meta para terminar cada episodio. Usé Q-learning con alfa 0.5, gamma 1, epsilon 0.1, 500 episodios y semilla 42. La tabla Q empezó en cero. En los empates elegí primero N, luego E, S y W. Puse un máximo de 200 pasos por episodio.

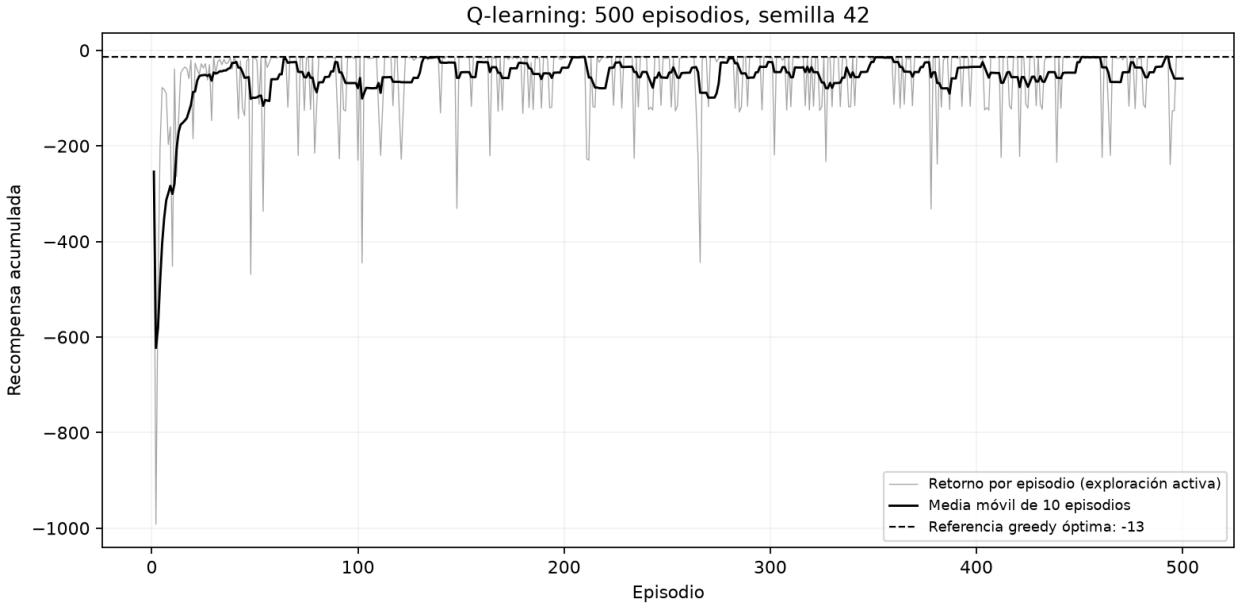
Después de entrenar, probé la política sin exploración, con epsilon 0. El agente llegó a la meta en 13 pasos y obtuvo un retorno de -13. Su recorrido fue un paso al norte, once al este y uno al sur. Este camino es óptimo porque tiene que avanzar once columnas, subir para evitar el acantilado y bajar para entrar a la meta. Todo eso requiere al menos 13 pasos. Cualquier desvío agrega pasos y caer empeora mucho la recompensa.

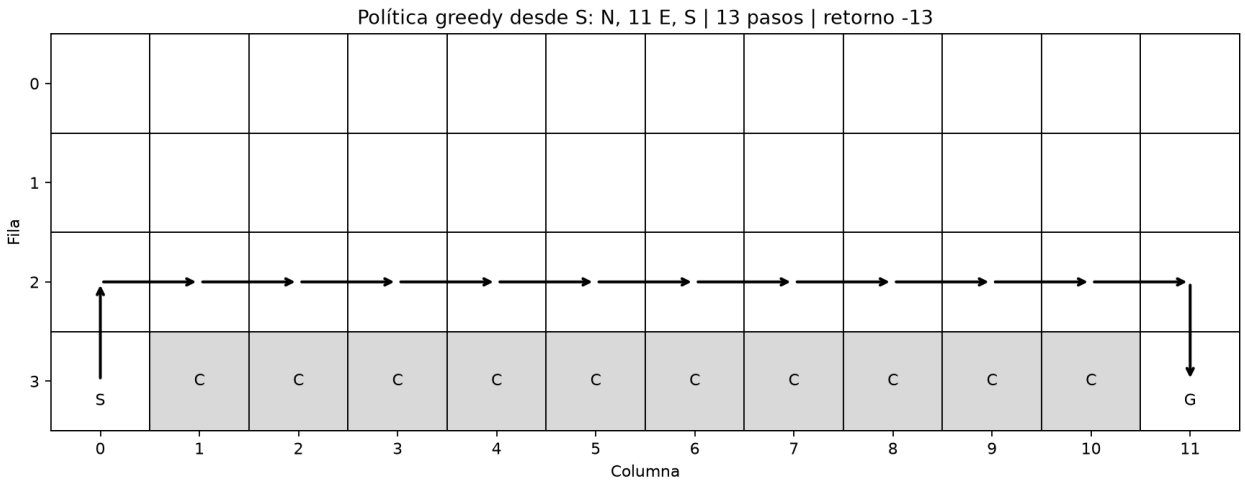
La recompensa promedio de los primeros 50 episodios fue -111.96. En los últimos 50 fue -42.06. Durante el entrenamiento hubo 167 caídas y 2 episodios llegaron al límite de pasos. El promedio de entrenamiento quedó por debajo de -13 porque epsilon 0.1 hace que el agente pruebe acciones al azar. Aunque ya conozca el camino, puede alejarse o caer y recibir -100. La evaluación de -13 usa solamente las mejores acciones aprendidas.

Al caer, el siguiente estado es el inicio S=(3,0). La actualización usa -100 + gamma por el mayor valor Q del inicio. No usa futuro cero porque la caída no termina el episodio. El futuro cero se usa al entrar a la meta. Comprobé estas transiciones y la ruta de 13 pasos durante la ejecución.

La gráfica de los 500 episodios, el camino aprendido y la captura de la consola se incluyen en este documento.

Recompensa de los 500 episodios de entrenamiento.




Política greedy desde S: N, 11 E, S | 13 pasos | retorno -13
Fila
Columna
S
G
C

Evidencias de ejecución

terminal 8a

